

**Peramalan Jangka Pendek Harga Saham INDF (PT Indofood  
Sukses Makmur Tbk) Menggunakan Model ARIMA**



*Intelligentia - Dignitas*

Dosen Pengampu:

Dra. Widyanti Rahayu, M.Si.

Disusun Oleh:

Rafi King Akbar (1314623018)

**Program Studi Statistika**

**Fakultas Matematika dan Ilmu Pengetahuan Alam**

**Universitas Negeri Jakarta**

**2025**

## Daftar Isi

Daftar Isi.....	i
BAB I PENDAHULUAN .....	1
1.1    Latar Belakang .....	1
1.2    Rumusan Masalah .....	2
1.3    Tujuan Penelitian.....	2
BAB II TINJAUAN PUSTAKA .....	3
2.1    Saham dan Harga Penutupan .....	3
2.2    Deret Waktu dan Komponennya .....	4
2.3    Stasioneritas dalam Deret Waktu .....	5
2.4    Model ARIMA ( <i>Autoregressive Integrated Moving Average</i> ).....	7
2.5 <i>Mean Absolute Percentage Error</i> (MAPE).....	9
2.6 <i>Mean Absolute Error</i> (MAE) .....	10
2.7    Mean Squared Error (MSE) .....	10
BAB III METODOLOGI PENELITIAN.....	12
3.1    Metode Penelitian.....	12
3.2    Sumber data.....	12
3.3    Langkah-Langkah Penelitian .....	14
BAB IV HASIL DAN PEMBAHASAN.....	16
4.1 Analisis Data Awal .....	16
4.2 Pengujian Stasioneritas .....	16
4.3 Identifikasi dan Penentuan Model ARIMA.....	20
4.4 Pembangunan, Pelatihan, dan Evaluasi Model .....	22
4.5 Diagnostik Residual Model.....	25

4.6 Implementasi Peramalan .....	26
BAB V KESIMPULAN DAN SARAN.....	29
5.1 Kesimpulan .....	29
5.2 Saran.....	30
DAFTAR PUSTAKA.....	31
LAMPIRAN.....	32

# **BAB I**

## **PENDAHULUAN**

### **1.1 Latar Belakang**

Saham merupakan bentuk kepemilikan atas suatu perusahaan yang memberikan hak kepada pemegangnya atas sebagian laba dan kekayaan perusahaan. Pergerakan harga saham yang fluktuatif menjadi cerminan dari dinamika internal perusahaan serta sentiment pasar terhadap kondisi ekonomi secara keseluruhan (Mankiw, 2019).

Data harga saham PT Indofood Sukses Makmur Tbk (INDF) dari tanggal 1 Januari 2022 hingga 31 Desember 2024 dipilih sebagai objek kajian karena relevansinya yang kuat terhadap kondisi ekonomi domestik. Indofood, sebagai salah satu perusahaan pangan terbesar di Indonesia, memiliki pengaruh signifikan terhadap sektor konsumsi dan stabilitas harga kebutuhan pokok. Pergerakan harga saham INDF tidak hanya dipengaruhi oleh kinerja keuangan perusahaan, tetapi juga oleh fluktuasi harga komoditas global, inflasi pangan, serta kebijakan pemerintah dalam pengendalian harga bahan pokok.

Selama periode tersebut, Indonesia menghadapi berbagai perubahan ekonomi pascapandemi yang turut memengaruhi perilaku pasar modal, termasuk volatilitas di sektor konsumsi. Situasi ini menjadikan harga saham INDF sebagai indikator yang menarik untuk dianalisis secara lebih dalam, khususnya dalam konteks pola pergerakan jangka pendek.

Untuk mengidentifikasi dan meramalkan kecenderungan harga saham dalam jangka pendek, digunakan pendekatan statistic berbasi deret waktu. Salah satu metode yang digunakan pendekatan statistic berbasis deret waktu. Salah satu metode yang digunakan dalam penelitian ini adalah model ARIMA, yang telah banyak diterapkan dalam studi-studi sebelumnya untuk mengamati pola data historis dan melakukan proyeksi terhadap nilai di masa mendatang. Melalui pendekatan ini, diharapkan diperoleh gambaran umum mengenai arah pergerakan harga saham INDF berdasarkan tren data sebelumnya.

## **1.2 Rumusan Masalah**

Dalam dinamika pasar keuangan yang terus berubah, harga saham tidak hanya mencerminkan kondisi internal suatu perusahaan, tetapi juga menjadi cerminan dari ekspektasi pasar terhadap berbagai faktor ekonomi, sosial, dan kebijakan publik. Saham PT Indofood Sukses Makmur Tbk (INDF), sebagai bagian dari sektor konsumsi yang strategis di Indonesia, mencatatkan pergerakan harga yang menarik untuk dikaji dalam kurun waktu tertentu. Namun, meskipun tersedia data historis secara lengkap, belum banyak kajian yang secara spesifik menggali bagaimana pola pergerakan harga saham ini terbentuk dan berubah dari waktu ke waktu. Dalam konteks tersebut, pertanyaan pertama yang muncul adalah bagaimana kecenderungan atau pola fluktuasi harga saham INDF terbentuk selama periode 1 Januari 2022 hingga 31 Desember 2024. Lebih lanjut, penting untuk ditelaah bagaimana pendekatan deret waktu dapat digunakan secara sistematis untuk menganalisis karakteristik data historis tersebut, termasuk apakah model seperti ARIMA mampu menangkap struktur pola yang tersembunyi di balik fluktuasi data. Akhirnya, timbul pertanyaan mengenai sejauh mana model tersebut dapat memberikan gambaran pergerakan harga saham INDF dalam jangka pendek, dan apakah hasilnya dapat diandalkan untuk keperluan prediksi berdasarkan perilaku masa lalu.

## **1.3 Tujuan Penelitian**

Penelitian ini bertujuan untuk menganalisis pola pergerakan harga saham PT Indofood Sukses Makmur Tbk (INDF) berdasarkan data historis yang tersedia, guna memperoleh pemahaman mendalam mengenai dinamika yang terjadi di pasar saham sektor konsumsi. Selain itu, penelitian ini dimaksudkan untuk menerapkan pendekatan deret waktu dalam mengidentifikasi struktur dan karakteristik fluktuasi harga yang muncul. Melalui penerapan model ARIMA, penelitian ini juga bertujuan untuk membangun proyeksi jangka pendek yang dapat menggambarkan kecenderungan harga saham di masa mendatang, sebagai upaya untuk melihat sejauh mana data masa lalu dapat digunakan sebagai dasar peramalan yang representatif.

## BAB II

### TINJAUAN PUSTAKA

#### 2.1 Saham dan Harga Penutupan

Saham merupakan salah satu instrument keuangan yang paling umum diperdagangkan di pasar modal. Dalam konteks ekonomi, saham didefinisikan sebagai bukti kepemilikan seseorang atas suatu perusahaan. Pemilik saham memiliki hak atas sebagian dari keuntungan perusahaan serta, dalam beberapa kasus, hak suara dalam pengambilan Keputusan strategis perusahaan. Menurut (Mankiw, 2019), saham adalah sertifikat kepemilikan dalam suatu perusahaan yang memberikan pemiliknya klaim atas laba yang dihasilkan perusahaan serta atas aset perusahaan tersebut.

Perdagangan saham terjadi melalui bursa efek, dan harga saham dapat berubah setiap saat tergantung pada permintaan dan penawaran yang terbentuk di pasar. Faktor-faktor yang memengaruhi harga saham meliputi kondisi fundamental perusahaan, ekspektasi investor, serta kondisi ekonomi makro secara keseluruhan. Dalam praktiknya, harga saham yang digunakan sebagai dasar analisis sering kali merujuk pada harga penutupan (*closing price*).

Harga penutupan adalah harga terakhir dari suatu saham yang tercatat pada akhir sesi perdagangan harian. Harga ini dianggap penting karena mencerminkan sentiment pasar pada hari tersebut dan menjadi referensi utama dalam berbagai bentuk analisis teknikal maupun fundamenral. Dalam analisis teknikal, harga penutupan digunakan untuk menghitung indikator seperti *moving average*, *Relative Strength Index* (RSI), dan lainnya. Dalam konteks penelitian ini, harga penutupan saham PT Indofood Sukses Makmur Tbk (INDF) dipilih karena sifatnya yang stabil dan representative terhadap dinamika pasar konsumsi di Indonesia.

Harga penutupan juga menjadi dasar perhitungan dalam model-model peramalan seperti ARIMA. Karena data historis yang digunakan berbentuk runtun waktu berdasarkan harga penutupan harian, maka penting untuk memahami bahwa pergerakan harga ini tidak hanya dipengaruhi oleh kondisi perusahaan, tetapi juga oleh sentiment pasar, berita global, dan faktor eksternal lainnya

## **2.2 Deret Waktu dan Komponennya**

Deret waktu (*time series*) merupakan rangkaian observasi terhadap suatu variabel yang dicatat secara berurutan dalam waktu, biasanya pada interval waktu yang tetap, seperti harian, mingguan, atau bulanan. Menurut (D. Cryer & Chan, 2008), deret waktu bertujuan untuk memodelkan proses stokastik yang menghasilkan data tersebut serta untuk meramalkan nilai-nilai di masa depan berdasarkan pola masa lalu.

Dalam praktik analisis, deret waktu sering kali tidak hanya berupa angka-angka acak, melainkan memiliki struktur tertentu yang dapat dikaji lebih lanjut. Menurut (Hyndman & Athanasopolus, 2018), sebagian besar deret waktu dapat dijelaskan melalui empat komponen utama, yaitu:

### **1. Tren (*Trend*)**

Tren merupakan pola perubahan jangka panjang dalam nilai rata-rata deret waktu, yang dapat berupa kenaikan, penurunan, atau kestabilan. Tren mencerminkan perubahan yang bersifat sistematis, seperti pertumbuhan ekonomi atau perkembangan bisnis dalam jangka panjang.

### **2. Musiman (*Seasonality*)**

Musiman menunjukkan pola fluktuasi yang berulang secara teratur dalam periode waktu tetap, seperti bulanan atau tahunan. Komponen ini sering kali berkaitan dengan faktor kalender atau siklus aktivitas yang konsisten dalam industri tertentu.

### **3. Siklus (*Cycle*)**

Komponen siklus mengacu pada fluktuasi yang terjadi dalam jangka waktu lebih panjang namun tidak memiliki periode yang tetap seperti musiman. Siklus umumnya berhubungan dengan dinamika ekonomi, seperti fase ekspansi dan resesi, serta lebih sulit diprediksi.

### **4. Komponen Acak (*Irregular/Noise*)**

Komponen acak mencerminkan variasi yang tidak dapat diprediksi dan tidak memiliki pola tertentu. Fluktuasi ini biasanya bersifat sementara dan disebabkan oleh kejadian yang tidak terduga, seperti perubahan kebijakan, bencana, atau peristiwa geopolitik.

Keempat komponen tersebut tidak selalu muncul secara bersamaan, namun pemahaman terhadap masing-masing sangat penting dalam proses permodelan dan peramalan. Analisis deret waktu yang efektif bergantung pada kemampuan untuk mengidentifikasi struktur data dan memilih model yang dapat menangkap karakteristik tersebut secara akurat.

### **2.3 Stasioneritas dalam Deret Waktu**

Stasioneritas merupakan konsep fundamental dalam analisis deret waktu yang berkaitan dengan kestabilan sifat statistik suatu proses sepanjang waktu. Suatu deret waktu dikatakan stasioner apabila karakteristik utamanya, seperti nilai rata-rata, varians, dan autokorelasi, bersifat konstan terhadap waktu. Deret waktu yang tidak stasioner dapat menunjukkan adanya tren atau perubahan pola variabilitas yang dapat mengganggu ketepatan dalam pemodelan dan peramalan.

Menurut (D. Cryer & Chan, 2008), stasioneritas terbagi menjadi dua jenis, yaitu stasioneritas kuat dan stasioneritas lemah. Dalam praktik analisis, fokus umumnya pada stasioneritas lemah, yang ditandai oleh tiga syarat: (1) rata-rata tetap, (2) varians tetap dan terbatas, serta (3) kovarians antara dua waktu hanya bergantung pada selisih waktu (lag), bukan pada titik waktu itu sendiri. Sifat ini memungkinkan proses deret waktu dimodelkan dengan pendekatan statistik yang konsisten.

Untuk menentukan apakah suatu deret waktu stasioner, terdapat beberapa pendekatan yang umum digunakan:

#### **1. Pemekrisaan Visual**

Pemeriksaan awal dapat dilakukan melalui visualisasi deret waktu. Jika deret menunjukkan pola tren meningkat/menurun atau fluktuasi varians yang berubah dari waktu ke waktu, maka kemungkinan besar deret tersebut tidak stasioner.

#### **2. Plot Autocorrelation Function (ACF) dan Partial Autocorrelation Function (PACF)**



- ACF mengukur kekuatan hubungan antara nilai deret saat ini dengan nilai-nilai sebelumnya pada berbagai lag. Jika ACF menurun secara perlahan (slow decay), ini menunjukkan pola tidak stasioner.
- PACF menunjukkan korelasi antara observasi saat ini dan lag tertentu setelah menghilangkan efek lag-lag lainnya. Deret stasioner umumnya menunjukkan cut-off cepat pada ACF atau PACF setelah beberapa lag pertama.

### 3. Uji Statistik (Augmented Dickey-Fuller Test)

Uji ADF merupakan pengembangan dari uji Dickey-Fuller yang digunakan untuk menguji apakah suatu proses memiliki akar unit, yang merupakan ciri dari ketidakstasioneran. Persamaan regresi ADF secara umum dituliskan sebagai berikut (Damodar N, 2004):

$$\Delta Y_t = \beta_1 + \beta_2 t + \delta Y_{t-1} + \sum_{i=1}^m \alpha_i \Delta Y_{t-i} + \epsilon_t$$

Di mana:

Simbol	Makna
$\Delta Y_t$	Perubahan nilai deret waktu pada periode ke- $t$ , yaitu $Y_t - Y_{t-1}$ . Ini disebut <i>first differencing</i> dan merupakan variabel dependen dalam model ADF.
$\beta_1$	Intersep (konstanta) dari model regresi.
$\delta Y_{t-1}$	Produk antara koefisien $\delta$ dan nilai deret waktu pada periode sebelumnya. Inilah bagian utama yang diuji dalam ADF.
$\sum_{i=1}^m \alpha_i \Delta Y_{t-i}$	Koreksi terhadap autokorelasi residual, dengan menambahkan sejumlah lag dari differenced variable. Ini disebut augmentasi, dan

bertujuan agar galat  $\epsilon_t$  menjadi white noise.

Pengujian dilakukan terhadap hipotesis nol bahwa  $\delta = 0$ , yang menunjukkan adanya akar unit (tidak stasioner). Jika hipotesis nol ditolak, maka data dianggap stasioner.

Jika suatu deret tidak stasioner, metode transformasi yang umum digunakan untuk menjadikannya stasioner adalah *differencing*, yaitu menghitung selisih antara nilai sekarang dengan nilai sebelumnya:

$$Y'_t = Y_t - Y_{t-1}$$

Metode ini bertujuan untuk menghilangkan tren atau fluktuasi non-konstan dari rata-rata. Apabila satu kali *differencing* belum cukup, maka dapat dilakukan *differencing* tingkat kedua dan seterusnya hingga sifat stasioner tercapai. Dalam model ARIMA, jumlah *differencing* diwakili oleh parameter  $d$ .

## 2.4 Model ARIMA (*Autoregressive Integrated Moving Average*)

Model ARIMA (*Autoregressive Integrated Moving Average*) merupakan salah satu pendekatan deret waktu yang banyak digunakan untuk menganalisis data non-stasioner. Menurut (D. Cryer & Chan, 2008), model ini merupakan pengembangan dari model ARMA dengan menambahkan proses *differencing*, sehingga dapat menangani deret waktu yang belum stasioner secara statistik.

Model ARIMA dinotasikan sebagai ARIMA ( $p, d, q$ ), dengan:

- $p$  menunjukkan orde komponen *autoregressive* (AR),
- $d$  adalah jumlah *differencing* yang diperlukan untuk mencapai stasioneritas,
- $q$  menyatakan orde komponen *moving average* (MA).

Model ini menggabungkan tiga komponen utama sebagai berikut:

### 1. *Autoregressive* (AR)

Komponen ini menjelaskan bahwa nilai saat ini dalam deret waktu bergantung pada nilai-nilai masa lalu. Model AR orde- $p$  dapat dituliskan sebagai:

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \epsilon_t$$

Di mana  $\phi_i$  adalah parameter model dan  $\epsilon_t$  adalah galat acak yang diasumsikan *white noise*.

## 2. *Integrated (I)*

Komponen ini merepresentasikan proses *differencing*, yaitu pengurangan nilai saat ini dengan nilai sebelumnya, untuk menghilangkan tren atau variasi jangka panjang sehingga data menjadi stasioner. Proses *differencing* pertama dirumuskan sebagai:

$$\Delta Y_t = Y_t - Y_{t-1}$$

Jumlah *differencing* yang dibutuhkan ditentukan oleh tingkat ketidakstasioneran data.

## 3. *Moving Average (MA)*

Komponen MA menunjukkan bahwa nilai saat ini dalam deret waktu dipengaruhi oleh kombinasi linier dari residual masa lalu. Model MA orde- $q$  dirumuskan sebagai:

$$Y_t = \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \dots + \theta_q \epsilon_{t-q}$$

Di mana  $\theta_j$  adalah parameter untuk galat pada lag ke- $j$ .

Model ARIMA banyak diterapkan dalam data ekonomi dan keuangan karena fleksibilitasnya dalam menangani data runtun waktu tanpa memerlukan variabel eksternal tambahan. Dalam konteks deret waktu harga saham, yang umumnya bersifat non-stasioner dan menunjukkan pola tren serta autokorelasi, model ARIMA menjadi salah satu pendekatan yang relevan dan efisien untuk kebutuhan peramalan jangka pendek.

## Kriteria Pemilihan Model ARIMA

Dalam proses pemilihan model ARIMA terbaik, digunakan kriteria tertentu untuk mengevaluasi berbagai kombinasi nilai  $p$ ,  $d$ , dan  $q$ . Salah satu kriteria yang paling umum adalah *Akaike Information Criterion* (AIC). AIC mengukur kualitas model dengan mempertimbangkan *trade-off* antara *goodness-of-fit* dan kompleksitas

model. Semakin rendah nilai AIC, maka model dianggap semakin baik. AIC didefinisikan sebagai:

$$AIC = -2 \ln(L) + 2k$$

Di mana  $L$  adalah nilai *likelihood* dari model dan  $k$  adalah jumlah parameter yang diestimasi. Kriteria ini membantu dalam memilih model yang efisien namun tetap sederhana, dan digunakan secara luas dalam implementasi otomatis seperti fungsi `auto.arima()` dalam perangkat lunak R.

Selain menggunakan pendekatan otomatis melalui fungsi `auto.arima()`, pemilihan parameter  $p$  dan  $q$  pada model ARIMA juga dapat dilakukan secara manual dengan menganalisis pola grafik ACF dan PACF. ACF digunakan untuk mengidentifikasi orde *moving average* (MA), ditandai dengan pola *cut-off* tajam pada lag ke- $q$ , sementara PACF digunakan untuk menentukan orde *autoregressive* (AR), ditunjukkan oleh *cut-off* pada lag ke- $p$ . Pendekatan manual ini sering digunakan untuk mendapatkan pemahaman yang lebih mendalam terhadap struktur autokorelasi dalam data deret waktu.

## 2.5 Mean Absolute Percentage Error (MAPE)

*Mean Absolute Percentage Error* (MAPE) adalah metrik evaluasi yang digunakan untuk mengukur rata-rata kesalahan dalam bentuk persentase relatif terhadap nilai aktual. MAPE bersifat intuitif karena menunjukkan seberapa besar deviasi prediksi dari nilai sebenarnya dalam satuan persen, sehingga mudah digunakan untuk membandingkan performa antar model atau antar periode.

Namun demikian, seperti dijelaskan oleh (Chicco, J. Warrens, & Jurman, 2021), MAPE memiliki keterbatasan: metrik ini hanya dapat digunakan jika nilai aktual bersifat positif. Selain itu, MAPE cenderung memberikan bias yang besar ketika nilai aktual mendekati nol, karena nilai kesalahan relatif menjadi sangat tinggi.

Rumus perhitungan MAPE dinyatakan sebagai berikut:

$$PE_i = \frac{e_i}{y_i} \times 100\%$$

$$MAPE = \frac{1}{n} \sum_{i=1}^n |PE_i|$$

Dengan  $e_i = y_i - \hat{y}_i$ , yaitu selisih antara nilai aktual dan prediksi.

## 2.6 Mean Absolute Error (MAE)

*Mean Absolute Error* (MAE) merupakan metrik evaluasi yang menghitung rata-rata kesalahan absolut antara nilai aktual dan nilai prediksi. MAE banyak digunakan karena bersifat robust terhadap pencilan (*outlier*) dan memberikan gambaran rata-rata kesalahan dalam satuan asli dari data.

Menurut (Chicco, J. Warrens, & Jurman, 2021), MAE menggunakan normal  $L_1$ , yaitu menghitung nilai absolut dari tiap kesalahan tanpa mengkuadratkannya. Hal ini membuat MAE tidak memperbesar pengaruh kesalahan ekstrem seperti yang terjadi pada MSE. Oleh karena itu, MAE cocok digunakan ketika kestabilan terhadap gangguan acak atau noise diperlukan dalam model. Persamaan MAE adalah sebagai berikut:

$$e_i = y_i - \hat{y}_i$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |e_i|$$

## 2.7 Mean Squared Error (MSE)

*Mean Squared Error* (MSE) merupakan metrik evaluasi yang menghitung rata-rata dari kuadrat selisih antara nilai aktual dan nilai prediksi. MSE sangat sensitif terhadap nilai pencilan karena menggunakan norma  $L_2$ , di mana kesalahan dikuadratkan sehingga memberikan penalti yang lebih besar terhadap deviasi besar.

Seperti yang dijelaskan oleh (Chicco, J. Warrens, & Jurman, 2021), sensitivitas ini menjadikan MSE relevan dalam konteks di mana kesalahan besar harus dideteksi atau diminimalkan, seperti dalam kasus prediksi nilai ekstrem. MSE juga memiliki

hubungan yang erat dengan nilai koefisien determinasi ( $R^2$ ), sehingga banyak digunakan dalam evaluasi model regresi.

$$e_i = y_i - \hat{y}_i$$

$$MSE = \frac{1}{n} \sum_{i=1}^n |e_i^2|$$

## **BAB III**

### **METODOLOGI PENELITIAN**

#### **3.1 Metode Penelitian**

Penelitian ini merupakan penelitian kuantitatif dengan pendekatan analisis deret waktu. Pendekatan ini digunakan untuk mengamati dan memodelkan data yang tersusun secara kronologis, dengan tujuan mengidentifikasi pola historis dan melakukan peramalan terhadap nilai di masa mendatang.

Fokus penelitian terletak pada harga penutupan saham harian PT Indofood Sukses Makmur Tbk (INDF), yang dianalisis dalam bentuk deret waktu. Proses analisis mencakup eksplorasi pola data, pengujian stasioneritas, serta pemilihan dan penerapan model *Autoregressive Integrated Moving Average* (ARIMA) sebagai alat peramalan.

Selain itu, analisis dilakukan secara deskriptif melalui visualisasi data dan evaluasi performa model menggunakan kriteria statistik seperti *Mean Absolute Percentage Error* (MAPE), *Mean Absolute Error* (MAE), dan *Mean Squared Error* (MSE). Pendekatan ini memungkinkan peneliti untuk membangun model peramalan yang akurat dan relevan terhadap dinamika data deret waktu tanpa melibatkan variabel independen lain.

#### **3.2 Sumber data**


Data yang digunakan dalam penelitian ini merupakan data deret waktu (*time series*) berupa harga penutupan saham harian PT Indofood Sukses Makmur Tbk (INDF). Data ini diperoleh secara bebas melalui situs Investing.com yang dapat diakses melalui tautan <https://id.investing.com/equities/indofood-s-m-t-historical-data>. Periode data yang digunakan adalah dari tanggal 1 Januari 2021 hingga 31 Mei 2024, mencakup total sebanyak 722 observasi harian. Pemilihan saham INDF didasarkan pada karakteristiknya sebagai saham yang aktif diperdagangkan (likuid), berasal dari sektor konsumsi yang stabil, serta mencerminkan kondisi umum pasar saham di Indonesia.

	Tanggal	Terakhir	Pembukaan	Tertinggi	Terendah	Vol.	Perubahan%
0	30/12/2024	7.700	7.700	7.750	7.650	4,83M	0,00%
1	27/12/2024	7.700	7.650	7.725	7.625	3,65M	0,98%
2	24/12/2024	7.625	7.725	7.725	7.600	3,63M	-1,29%
3	23/12/2024	7.725	7.675	7.800	7.650	5,53M	1,31%
4	20/12/2024	7.625	7.650	7.750	7.600	14,59M	-0,33%
...	...	...	...	...	...	...	...
717	07/01/2022	6.425	6.350	6.450	6.325	10,17M	1,98%
718	06/01/2022	6.300	6.225	6.300	6.225	4,72M	1,20%
719	05/01/2022	6.225	6.300	6.300	6.200	10,38M	-0,80%
720	04/01/2022	6.275	6.250	6.325	6.250	9,18M	0,40%
721	03/01/2022	6.250	6.325	6.350	6.250	7,16M	-1,19%

722 rows x 7 columns

*Gambar 1. Tabel data harga penutupan saham INDF*

Gambar 1 menyajikan cuplikan sebagian data mentah yang digunakan dalam penelitian, yang terdiri dari beberapa variabel seperti tanggal, harga penutupan, harga pembukaan, harga tertinggi, harga terendah, volume transaksi, dan persentase perubahan. Variabel utama yang digunakan dalam analisis adalah kolom "Terakhir", yaitu harga penutupan harian saham, karena variabel ini paling umum digunakan dalam pemodelan dan peramalan harga saham.



*Gambar 2. Grafik harga penutupan saham INDF*

Selanjutnya, Gambar 2 menampilkan visualisasi awal dalam bentuk grafik time series dari harga penutupan saham INDF selama periode pengamatan. Grafik ini memberikan gambaran awal mengenai pola pergerakan harga, termasuk tren jangka panjang dan fluktuasi jangka pendek yang tampak cukup signifikan. Pola pergerakan yang tidak sepenuhnya acak ini menunjukkan bahwa data memiliki potensi untuk dimodelkan menggunakan metode deret waktu seperti ARIMA.



Visualisasi ini juga berfungsi sebagai dasar awal untuk menentukan apakah data perlu ditransformasi atau dilakukan pembedaan (*differencing*) sebelum memasuki tahap pemodelan lanjutan.

### **3.3 Langkah-Langkah Penelitian**

Penelitian ini dilakukan melalui tahapan sistematis untuk membangun model ARIMA dalam meramalkan harga penutupan saham PT Indofood Sukses Makmur Tbk (INDF). Langkah-langkah penelitian adalah sebagai berikut:

#### **1. Pengumpulan Data**

Mengambil data historis harga penutupan saham INDF dari sumber terpercaya secara daring, lalu memuatnya ke dalam sistem analisis data untuk pengolahan lebih lanjut.

#### **2. Analisis Data Eksploratif**

Melakukan analisis deksriptif awal guna memahami pola dan karakteristik data, termasuk ringkasan statistik, pemeriksaan struktur data, serta visualisasi awal data deret waktu. Tahap ini juga mencakup identifikasi adanya data yang hilang.

#### **3. Penanganan Data Hilang**

Apabila terdapat data hilang pada harga penutupan, dilakukan proses imputasi menggunakan interpolasi linier agar kelengkapan data terjaga dan siap untuk tahap pemodelan.

#### **4. Pengujian Stasioneritas**

Mengevaluasi sifat stasioneritas data, baik dari sisi rata-rata (mean) maupun ragam (varians). Jika data tidak stasioner dalam rata-rata, dilakukan *differencing*, sedangkan jika tidak stasioner dalam ragam dapat diterapkan transformasi logaritmik.

#### **5. Analisis ACF dan PACF**

Membuat grafik fungsi autokorelasi (ACF) dan fungsi autokorelasi parsial (PACF) dari data yang telah di stasionerkan, guna membantu dalam penentuan dugaan nilai parameter orde ARIMA, khususnya p dan q.

#### **6. Penentuan Parameter Model ARIMA**

Menentukan nilai parameter  $p$ ,  $d$ , dan  $q$  berdasarkan hasil analisis stasioneritas serta pola yang muncul pada grafik ACF dan PACF, sebagai tahapan awal Pembangunan model ARIMA.

#### **7. Pelatihan Model**

Melatih model ARIMA menggunakan data pelatihan (data train) yang diambil secara berurutan dari 80% bagian awal data, untuk mempelajari pola historis dan karakteristik pergerakan harga penutupan saham INDF.

#### **8. Evaluasi Model**

Mengevaluasi kinerja model dengan menggunakan data pengujian (20% sisa data) melalui perhitungan indikator akurasi MAPE, MAE, MSE, guna memastikan keandalan hasil peramalan.

#### **9. Pemeriksaan Diagnostik**

Melakukan analisis residual model untuk memastikan tidak terdapat pola autokorelasi yang signifikan, varians residual stabil, dan distribusi residual mendekati normal, sehingga dapat dikatakan memenuhi asumsi white noise.

#### **10. Penerapan Peramalan**

Mengimplementasikan model ARIMA yang telah terverifikasi untuk menghasilkan prediksi harga penutupan saham INDF pada periode waktu mendatang sebagai keluaran penelitian.

## **BAB IV**

### **HASIL DAN PEMBAHASAN**

#### **4.1 Analisis Data Awal**

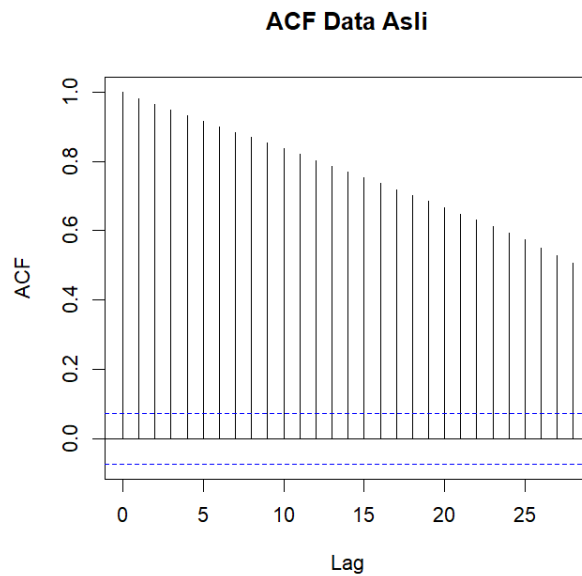
Analisis data awal dilakukan untuk memastikan kesiapan data sebelum proses pemodelan lanjutan. Data harga penutupan saham PT Indofood Sukses Makmur Tbk (INDF) yang digunakan dalam penelitian ini mencakup periode 1 Januari 2021 hingga 31 Mei 2024, dengan total 722 observasi harian. Jumlah observasi tersebut telah mempertimbangkan hari perdagangan aktif di Bursa Efek Indonesia, sehingga hari libur bursa tidak tercatat sebagai data hilang.

Hasil pemeriksaan nilai kosong atau nilai nol menunjukkan bahwa seluruh data harga penutupan telah terisi lengkap, sehingga tidak diperlukan proses imputasi tambahan. Dari hasil eksplorasi awal, pergerakan harga penutupan menunjukkan dinamika yang wajar di pasar saham, dengan pola tren meningkat pada periode akhir pengamatan. Selain itu, pergerakan harga juga mencerminkan volatilitas jangka pendek yang cukup signifikan, sesuai karakteristik saham sektor konsumsi yang aktif di perdagangan.

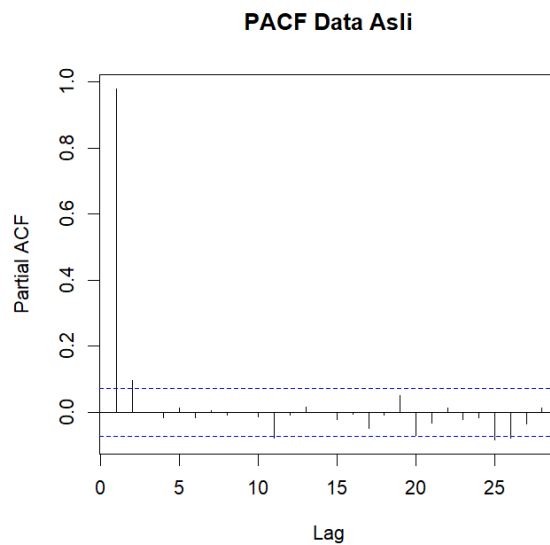
Karakteristik data ini penting untuk diperhatikan dalam tahap pemodelan deret waktu, agar proses identifikasi model dapat menangkap pola tren serta fluktuasi yang terjadi selama periode pengamatan secara optimal.

#### **4.2 Pengujian Stasioneritas**

Tahap pengujian stasioneritas dilakukan untuk memastikan bahwa data harga penutupan saham PT Indofood Sukses Makmur Tbk (INDF) memenuhi asumsi dasar deret waktu, yaitu bersifat stasioner. Pengujian ini dilakukan baik secara statistik menggunakan metode Augmented Dickey-Fuller (ADF) maupun secara visual melalui grafik ACF dan PACF.



Gambar 3. Grafik ACF Data Asli Harga Penutupan INDF

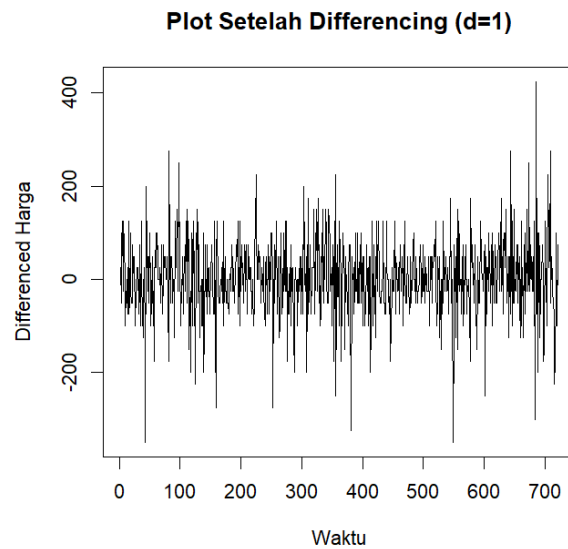


Gambar 4. Grafik PACF Data Asli Harga Penutupan INDF

Hasil visualisasi awal melalui grafik ACF (Gambar 3) memperlihatkan pola autokorelasi yang menurun secara perlahan (*slow decay*), sedangkan grafik PACF (Gambar 4) menunjukkan spike signifikan pada lag awal. Pola ini menandakan adanya komponen tren dalam data. Hal ini juga diperkuat oleh hasil uji ADF pada data asli tanpa transformasi, yang menghasilkan nilai statistik Dickey-Fuller sebesar  $-1.505$  dengan p-value sebesar  $0.7878$ . Karena nilai p-value ini jauh diatas

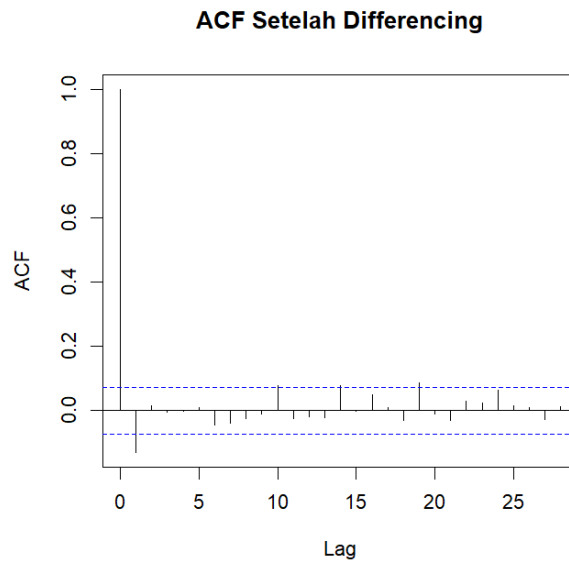
taraf signifikansi 5%, maka hipotesis nol tidak dapat ditolak, yang berarti data bersifat tidak stasioner.

Untuk mengatasi kondisi tersebut, dilakukan proses *differencing* satu kali ( $d=1$ ) guna menghilangkan tren pada data.




*Gambar 5. Plot Data Setelah Differencing ( $d=1$ )*

Setelah *differencing*, hasil uji ADF menunjukkan nilai statistik Dickey-Fuller sebesar  $-10.106$  dengan p-value lebih kecil dari 0.01 ( $p\text{-value} < 0.01$ ), sehingga hipotesis nol ketidakstasioneran dapat ditolak dan data dinyatakan stasioner. Hal ini juga tampak pada plot data setelah *differencing* (Gambar 5) yang berfluktuasi stabil di sekitar rata-rata nol tanpa pola tren dominan.



Gambar 6. Grafik ACF Setelah Differencing Harga Penutupan INDF



Gambar 7. Grafik PACF Setelah Differencing Harga Penutupan INDF

Grafik ACF setelah *differencing* (Gambar 6) menunjukkan pola *cut-off* yang cepat pada lag 1, sementara grafik PACF setelah *differencing* (Gambar 7) tetap menampilkan spike signifikan pada beberapa lag awal. Pola ini mengindikasikan adanya kemungkinan komponen *autoregressive* (AR) maupun *moving average* (MA) yang relevan untuk dipertimbangkan dalam pemodelan ARIMA pada tahap berikutnya.

Berdasarkan keseluruhan hasil uji ADF dan analisis visual, dapat disimpulkan bahwa data harga penutupan saham INDF telah memenuhi sifat stasioner dalam mean setelah dilakukan *differencing* satu kali, sehingga siap digunakan sebagai dasar identifikasi dan penentuan parameter model ARIMA selanjutnya.

#### 4.3 Identifikasi dan Penentuan Model ARIMA

Identifikasi model ARIMA bertujuan untuk menentukan nilai parameter  $p$ ,  $d$ , dan  $q$  sebelum proses Pembangunan model lebih lanjut. Nilai parameter  $d$  ditetapkan sebesar 1, sesuai hasil uji stasioneritas pada subbab sebelumnya, di mana data telah menjadi stasioner setelah dilakukan *differencing* satu kali.

Selanjutnya, nilai  $p$  dan  $q$  diidentifikasi dengan melihat pola grafik ACF dan PACF pada data yang telah distasionerkan. Grafik ACF setelah *differencing* (Gambar 6) menunjukkan pola *cut-off* yang relative cepat pada lag 1, sedangkan grafik PACF setelah *differencing* (Gambar 7) menampilkan spike signifikan pada lag awal, yang kemudian menurun pada lag-lag berikutnya. Berdasarkan pola ini, terdapat indikasi bahwa data memuat komponen *moving average* (MA) serta komponen autoregressive (AR).

Berdasarkan hasil interpretasi tersebut, beberapa kandidat model yang dianggap relevan untuk dievaluasi lebih lanjut antara lain:

- ARIMA (0,1,1)
- ARIMA (1,1,0)
- ARIMA (1,1,1)
- ARIMA (2,1,1)

Selain penentuan kandidat secara manual, proses identifikasi juga dilakukan secara otomatis menggunakan fungsi *auto.arima* pada perangkat R. Hasil dari *auto.arima* menunjukkan bahwa model ARIMA (0,1,1) adalah kandidat terbaik menurut nilai AIC terkecil di antara berbagai kombinasi parameter yang dievaluasi secara sistematis.

Model-model kandidat ini kemudian akan dikonfirmasi lebih lanjut pada tahap pembangunan dan pelatihan model di subbab berikutnya.

#### 4.3.1 Penentuan Model ARIMA Terbaik

Setelah proses identifikasi kandidat model melalui interpretasi pola ACF dan PACF pada subbab sebelumnya, tahap selanjutnya adalah menentukan model ARIMA terbaik dengan membandingkan beberapa kandidat secara kuantitatif. Pemilihan dilakukan menggunakan kriteria nilai *Akaike Information Criterion* (AIC) dan *Bayesian Information Criterion* (BIC), di mana nilai yang lebih kecil menunjukkan model yang lebih baik dalam menyeimbangkan kompleksitas dengan tingkat kesesuaian data.

Beberapa model kandidat yang dievaluasi meliputi ARIMA (0,1,1), ARIMA (1,1,0), ARIMA (1,1,1), dan ARIMA (2,1,1). Hasil ringkasan nilai AIC dan BIC dari masing-masing kandidat disajikan pada tabel berikut:

Model	AIC	BIC
ARIMA (0,1,1)	8454.96	8464.13
ARIMA (1,1,0)	8454.82	8463.98
ARIMA (1,1,1)	8456.82	8470.56
ARIMA (2,1,1)	8458.82	8477.14

Berdasarkan tabel di atas, model ARIMA (1,1,0) memiliki nilai AIC paling kecil yaitu 8454.82, diikuti ARIMA (0,1,1) dengan AIC 8454.96. Selisih nilai AIC di antara keduanya sangat kecil, yaitu sekitar 0.14, yang secara praktis dapat dianggap setara.

Analisis lebih lanjut terhadap koefisien model ARIMA (1,1,0) menunjukkan bahwa parameter AR(1) bernilai -0.1302 dengan *standard error* 0.0369, sehingga nilai  $|estimate|/std.error$  sekitar 3.5, yang menandakan parameter ini signifikan secara statistika (melebihi  $\pm 2$ ). Dengan demikian, AR(1) pada model ini dianggap signifikan.



Sementara itu, model ARIMA (0,1,1) memiliki koefisien MA(1) sebesar -0.1288 dengan *standard error* 0.0364, menghasilkan nilai rasio signifikan sekitar 3.5 pula. Artinya, kedua model memiliki parameter signifikan.

Dari segi nilai  $\sigma^2$ , ARIMA (1,1,0) sedikit lebih kecil (7209) dibanding ARIMA (0,1,1) (7210), namun perbedaan ini tergolong sangat kecil. Dengan demikian, keduanya sama-sama memadai dari segi varians residual.

Mengingat bahwa harga saham umumnya bersifat *random walk* dan sering kali *shock* jangka pendek (*noise*) lebih dominan daripada pola autoregressive, maka model ARIMA (0,1,1) dapat dipertimbangkan sebagai alternatif model terbaik meskipun nilai AIC-nya sedikit diatas ARIMA (1,1,0). Model ARIMA (0,1,1) juga konsisten dengan rekomendasi fungsi *auto.arima* sebelumnya, yang secara otomatis memilih model ini berdasarkan proses seleksi komprehensif.

Berdasarkan pertimbangan nilai AIC yang hamper identik, signifikansi parameter, teori *random-walk*, serta hasil *auto.arima*, penelitian ini menetapkan ARIMA (0,1,1) sebagai model akhir yang akan digunakan untuk proses pelatihan dan evaluasi lebih lanjut pada tahap berikutnya.


#### **4.4 Pembangunan, Pelatihan, dan Evaluasi Model**

##### **4.4.1 Pembangunan dan Pelatihan Model**

(Gambar 8) berikut menampilkan perbandingan antara data aktual dengan data hasil prediksi (*fitted*) selama periode pelatihan (*training*). Pada grafik ini digunakan data training sebesar 80% dari total data historis, yakni 578 observasi terawal, sebagai langkah *trim* agar model hanya dilatih pada data historis awal dan kemudian diuji di sisa 20% data selanjutnya. Hal ini bertujuan agar model tidak terpengaruh data testing saat proses pembelajaran.

Pada grafik terlihat garis berwarna hitam yang merepresentasikan data aktual harga penutupan saham INDF, sedangkan garis biru menunjukkan hasil prediksi (*fitted values*) dari model ARIMA (0,1,1) selama periode pelatihan. Secara visual, model ARIMA (0,1,1) berhasil mengikuti pergerakan harga historis dengan cukup baik,

meskipun terdapat deviasi pada beberapa titik dengan fluktuasi tajam, yang wajar dalam data saham yang volatil.



*Gambar 8. Grafik Data Aktual vs Fitted pada Data Training*

Setelah proses pelatihan dengan 80% data historis, diperoleh ringkasan karakteristik model sebagai berikut:

**1. Parameter MA(1):**

- *Estimate*: -0.1225
- *Standar error*: 0.0411
- Interpretasi: rasio  $|estimate|/std.error \approx 3$  (lebih besar dari 2)  $\rightarrow$  signifikan.
- Artinya *shock/error* satu periode sebelumnya berpengaruh terhadap harga saat ini.

**2.  $\sigma^2$  (ragam error):**

- Nilai: 6559
- Interpretasi: menunjukkan besarnya varians kesalahan prediksi model yang *relative* moderat untuk data saham.

**3. Log-likelihood:**

- Nilai: -3348.41
- Interpretasi: ukuran kecocokan model, semakin tinggi semakin baik (di sini sudah cukup stabil)

**4. AIC:**

- Nilai: 6700.82


- Interpretasi: dibanding kandidat lain, ARIMA (0,1,1) tetap kompetitif, mendukung pemilihan model ini.

Secara keseluruhan, model ARIMA(0,1,1) layak digunakan karena stabil dan berhasil menangkap pola fluktuasi harga dalam data training.

#### 4.4.2 Evaluasi Model

(Gambar 9) berikut menampilkan hasil prediksi model ARIMA(0,1,1) pada data testing (20% data sisa) dibandingkan dengan data aktual. Dalam grafik ini, garis berwarna merah menunjukkan data aktual periode *testing* (*out-of-sample*), sedangkan garis biru yang terdapat pada *forecast plot* mewakili nilai prediksi rata-rata model, dengan pita abu-abu sebagai interval kepercayaan (*confidence band*).

Dari grafik terlihat bahwa sebagian besar data aktual masih berada di dalam pita prediksi, meskipun ada beberapa deviasi pada saat harga mengalami perubahan tajam. Hal ini cukup wajar mengingat volatilitas harga saham seringkali sulit ditangkap sepenuhnya oleh model linier seperti ARIMA.



*Gambar 9. Plot Prediksi vs Aktual pada Data Testing dengan Model ARIMA (0,1,1)*

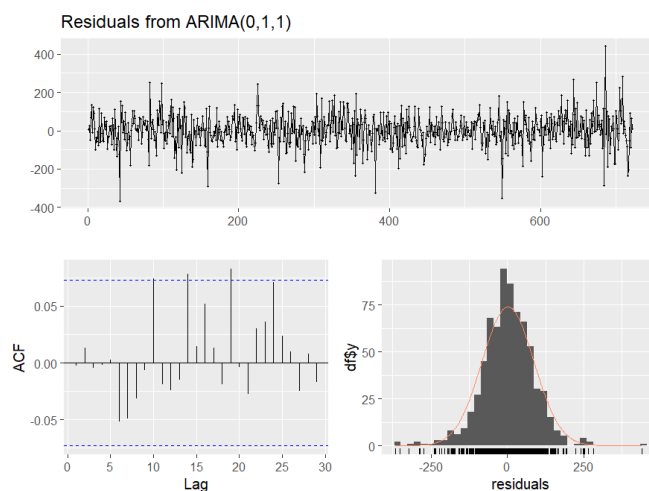
Hasil evaluasi kuantitatif di data testing dirangkum dalam tabel berikut:

Ukuran Error	Nilai
MAPE	13,73%
MAE	1010,53
MSE	1.520.956

Nilai MAPE yang tercatat sekitar 13,73% menunjukkan tingkat kesalahan prediksi masih dalam batas wajar untuk data saham yang fluktuatif, sedangkan MAE dan MSE memberikan gambaran bahwa deviasi prediksi juga masih dapat diterima. Dengan demikian, model ARIMA (0,1,1) dapat digunakan untuk memproyeksikan harga penutupan saham INDF pada periode jangka pendek dengan tingkat akurasi yang moderat.

#### 4.5 Diagnostik Residual Model

(Gambar 10) berikut menampilkan hasil pemeriksaan diagnostik residual dari model ARIMA (0,1,1) yang diestimasi menggunakan seluruh data historis harga penutupan saham INDF. Visualisasi ini mencakup tiga panel, yaitu plot residual terhadap waktu, histogram residual, serta plot ACF residual, yang digunakan secara terpadu untuk mengevaluasi apakah asumsi residual telah terpenuhi.



*Gambar 10. Hasil Diagnostik Residual Model ARIMA (0,1,1)*

Berdasarkan grafik di atas, diperoleh interpretasi sebagai berikut:

- **Plot residual terhadap waktu** (panel atas) menunjukkan fluktuasi residual yang stabil di sekitar rata-rata nol, tanpa pola tren atau pola musiman yang

mencolok. Ini menandakan kesalahan prediksi model bersifat acak dan tidak mengandung pola sistematis yang belum dijelaskan oleh model.

- **Histogram residual** (panel kanan bawah) menampilkan bentuk distribusi yang mendekati normal, meskipun terdapat sedikit skewness ke arah kiri dan beberapa pencilan (*outlier*). Namun, hal tersebut masih wajar pada data harga saham yang volatile.
- **Plot ACF Residual** (panel kiri bawah) memperlihatkan seluruh nilai autokorelasi residual berada di dalam batas signifikansi, sehingga tidak terdapat autokorelasi signifikan yang tersisa. Ini mendukung asumsi bahwa residual bersifat *white noise*.

Hasil uji Ljung-Box pada residual juga menguatkan Kesimpulan ini, dengan nilai statistik:


- $Q^*$  sebesar 8,6817,  $df = 9$
- p-value sebesar 0,4672

Karena p-value lebih besar dari taraf signifikansi 0,05, maka hipotesis nol (bahwa residual bersifat *white noise*) tidak ditolak. Artinya, residual model tidak menunjukkan pola autokorelasi yang signifikan dan memenuhi asumsi independensi.

Secara keseluruhan, pemeriksaan residual ini memastikan bahwa model ARIMA (0,1,1) sudah memenuhi asumsi dasar deret waktu, yaitu residual bersifat acak, stabil, dan mendekati distribusi normal. Dengan demikian, model dianggap valid untuk digunakan dalam tahap penerapan peramalan selanjutnya.

#### 4.6 Implementasi Peramalan

(Gambar 11) berikut menampilkan hasil penerapan model ARIMA (0,1,1) dalam melakukan peramalan harga penutupan saham PT Indofood Sukses Makmur Tbk (INDF) untuk horizon 30 hari ke depan. Model diimplementasikan pada keseluruhan data historis dari 1 Januari 2022 hingga 31 Desember 2024, sehingga parameter yang diperoleh memanfaatkan seluruh informasi data yang tersedia.



*Gambar 11. Plot Hasil Peramalan 30 Hari ke Depan dengan Model ARIMA (0,1,1)*

Pada grafik terlihat garis berwarna biru yang mewakili nilai prediksi rata-rata, sementara pita abu-abu menunjukkan interval kepercayaan 80% dan 95% yang mencerminkan rentang ketidakpastian prediksi. Model memproyeksikan harga penutupan saham INDF cenderung stabil di sekitar nilai rata-rata terakhir, dengan fluktuasi wajar mengikuti pola *random walk* yang lazim terjadi pada saham.

Secara lebih rinci, hasil prediksi 30 hari ke depan dapat disajikan dalam tabel berikut:

Tanggal	Prediksi Harga	Lower 80%	Upper 80%	Lower 95%	Upper 95%
2025-01-01	7698.94	7590.12	7807.76	7532.52	7865.37
2025-01-02	7698.94	7554.62	7843.27	7478.22	7919.67
2025-01-03	7698.94	7526.26	7871.62	7434.85	7963.03
2025-01-04	7698.94	7501.95	7895.94	7397.67	8000.22
2025-01-05	7698.94	7480.33	7917.56	7364.60	8033.29

(Keterangan: tabel lengkap prediksi 30 hari dapat dilihat di lampiran).

Prediksi ini diharapkan mampu memberikan gambaran kecenderungan harga penutupan saham INDF pada periode satu bulan ke depan, sebagai referensi tambahan bagi investor atau peneliti. Namun demikian, perlu dicatat bahwa model ARIMA bersifat linier dan tidak mempertimbangkan faktor eksternal seperti

kebijakan pemerintah, sentimen pasar, atau kondisi global, sehingga hasil peramalan sebaiknya tetap dikombinasikan dengan metode lain sebelum digunakan sebagai dasar keputusan investasi yang aktual.

## **BAB V**

### **KESIMPULAN DAN SARAN**

#### **5.1 Kesimpulan**

Berdasarkan hasil penelitian dan analisis yang telah dilakukan terhadap data harga penutupan saham PT Indofood Sukses Makmur Tbk (INDF) periode 1 Januari 2022 hingga 31 Desember 2024, dapat diambil beberapa kesimpulan sebagai berikut:

##### **1. Pola Pergerakan Harga**

Harga penutupan saham INDF menunjukkan karakteristik volatilitas harian yang cukup tinggi, dengan pola tren moderat tanpa pola musiman yang signifikan. Data historis ini cocok dimodelkan dengan pendekatan deret waktu.

##### **2. Analisis Stasioneritas dan Model Terbaik**

Hasil pengujian stasioneritas menunjukkan bahwa data aslinya tidak stasioner, sehingga dilakukan differencing satu kali ( $d=1$ ). Model ARIMA (0,1,1) teridentifikasi sebagai model terbaik berdasarkan nilai AIC terkecil dan pemeriksaan parameter signifikan.

##### **3. Evaluasi Model**

Model ARIMA (0,1,1) memiliki MAPE sekitar 13,73% pada data testing, yang dapat dianggap cukup moderat untuk konteks prediksi harga saham. Hasil pemeriksaan diagnostik residual juga memenuhi asumsi *white noise*, menegaskan bahwa model tidak meninggalkan pola autokorelasi pada error.

##### **4. Peramalan Jangka Pendek**

Model ARIMA (0,1,1) diterapkan untuk peramalan 30 hari ke depan mulai Januari 2025, menghasilkan prediksi harga penutupan yang relatif stabil di sekitar rata-rata historis terakhir. Meskipun demikian, fluktuasi tetap mungkin terjadi di luar rentang prediksi karena faktor eksternal yang tidak ditangkap model.

Dengan demikian, model ARIMA (0,1,1) layak digunakan untuk menggambarkan kecenderungan harga saham INDF dalam jangka pendek berbasis pola data masa lalu, walaupun tetap memiliki keterbatasan dalam menghadapi perubahan pasar yang bersifat mendadak.



## 5.2 Saran

1. Penelitian ini hanya menggunakan data harga penutupan harian tanpa memasukkan faktor fundamental atau sentimen pasar. Untuk penelitian selanjutnya, disarankan mempertimbangkan variabel eksternal seperti volume perdagangan, suku bunga, inflasi, atau data makroekonomi lain agar model menjadi lebih komprehensif.
2. ARIMA adalah model linier berbasis pola historis. Dalam menghadapi volatilitas saham yang tinggi, dapat dipertimbangkan penggunaan model non-linier atau hybrid (misalnya ARIMA–GARCH, *machine learning*) untuk meningkatkan akurasi prediksi.
3. Investor atau praktisi pasar modal diharapkan tidak menggunakan hasil prediksi ini sebagai dasar tunggal pengambilan keputusan investasi, melainkan mengombinasikannya dengan analisis lain seperti analisis fundamental dan analisis teknikal lanjutan.

## DAFTAR PUSTAKA

- Chicco, D., J. Warrens, M., & Jurman, G. (2021). The coefficient of determination R-squared. *PeerJ*, 5-6.
- D. Cryer, J., & Chan, K. S. (2008). *Time Series Analysis With Applications in R*.
- Damodar N, G. (2004). *BASIC ECONOMETRICS*.
- Hyndman, R. J., & Athanasopolus, G. (2018). *Forecasting: Principles and Practice (2nd ed)*.
- Mankiw, N. G. (2019). *Principles of Economics, Ninth Edition*. Cengage.

## LAMPIRAN

- Code dengan platform R

```
1 library(readr)
2 library(forecast)
3 library(tseries)
4 library(Metrics)
5
6 # -----
7 # 4.1 Analisis Data Awal
8 # -----
9
10 # 1. Baca data
11 data <- read.csv("C:/Users/Rafi/Downloads/Data Historis INDF (2).csv", colClasses = "character")
12 data$Tanggal <- as.Date(data$Tanggal, format = "%d/%m/%Y")
13 data <- data[order(data$Tanggal), ]
14
15 # 2. Konversi kolom harga ke numerik
16 data$Terakhir <- as.numeric(gsub(",", ".", gsub("\\.", "", data$Terakhir)))
17
18 # 3. Ringkasan statistik
19 cat("Ringkasan harga penutupan:\n")
20 summary(data$Terakhir)
21
22 # 4. Pengecekan data hilang / nol
23 na_count <- sum(is.na(data$Terakhir))
24 zero_count <- sum(data$Terakhir == 0)
25
26 cat("Jumlah data NA :", na_count, "\n")
27 cat("Jumlah data 0 :", zero_count, "\n")
28
29 # 5. Plot harga penutupan
30 plot(data$Tanggal, data$Terakhir, type="l",
31       main="Harga Penutupan Saham INDF",
32       xlab="Tanggal", ylab="Harga Penutupan")
33
34 # -----
35 # 4.2 Pengujian Stasioneritas
36 # -----
37
38 # Membuat time series
39 closing_ts <- ts(data$Terakhir, frequency=1)
40
41 # 1. Uji ADF pada data asli
42 cat("\nHasil ADF Test pada data asli:\n")
43 adf_asli <- adf.test(closing_ts)
44 print(adf_asli)
45
46 # 2. Plot data asli
47 plot(closing_ts,
48       main="Plot Harga Penutupan (Data Asli)",
49       ylab="Harga", xlab="waktu")
50
51 # 3. Plot ACF & PACF data asli
52 acf(closing_ts, main="ACF Data Asli")
53 pacf(closing_ts, main="PACF Data Asli")
54
55 # 4. Differencing 1x
56 diff_ts <- diff(closing_ts)
57
58 # 5. Uji ADF setelah differencing
59 cat("\nHasil ADF Test setelah differencing 1x:\n")
60 adf_diff <- adf.test(diff_ts)
61 print(adf_diff)
62
63 # 6. Plot data setelah differencing
64 plot(diff_ts,
65       main="Plot Setelah Differencing (d=1)",
66       ylab="Differenced Harga", xlab="waktu")
```

```

62
63 # 6. Plot data setelah differencing
64 plot(diff_ts,
65      main="Plot Setelah Differencing (d=1)",
66      ylab="Differenced Harga", xlab="Waktu")
67
68 # 7. Plot ACF & PACF data differencing
69 acf(diff_ts, main="ACF Setelah Differencing")
70 pacf(diff_ts, main="PACF Setelah Differencing")
71
72 # -----
73 # 4.3 Identifikasi dan Penentuan Model ARIMA
74 # -----
75 model_auto <- auto.arima(closing_ts)
76 cat("\nHasil auto.arima:\n")
77 print(summary(model_auto))
78
79 # -----
80 # 4.3.1 Penentuan Model ARIMA Terbaik
81 # -----
82
83 # menggunakan seluruh data
84 full_ts <- closing_ts
85
86 # a) ARIMA(0,1,1)
87 model_011 <- arima(full_ts, order=c(0,1,1))
88 aic_011 <- AIC(model_011)
89 bic_011 <- BIC(model_011)
90
91 # b) ARIMA(1,1,0)
92 model_110 <- arima(full_ts, order=c(1,1,0))
93 aic_110 <- AIC(model_110)
94 bic_110 <- BIC(model_110)
95
96 # c) ARIMA(1,1,1)
97 model_111 <- arima(full_ts, order=c(1,1,1))
98 aic_111 <- AIC(model_111)
99 bic_111 <- BIC(model_111)
100
101 # d) ARIMA(2,1,1)
102 model_211 <- arima(full_ts, order=c(2,1,1))
103 aic_211 <- AIC(model_211)
104 bic_211 <- BIC(model_211)
105
106 # Ringkasan tabel
107 cat("\nRingkasan AIC dan BIC kandidat model:\n")
108 kandidat_table <- data.frame(
109   Model = c("ARIMA(0,1,1)", "ARIMA(1,1,0)", "ARIMA(1,1,1)", "ARIMA(2,1,1)"),
110   AIC = c(aic_011, aic_110, aic_111, aic_211),
111   BIC = c(bic_011, bic_110, bic_111, bic_211)
112 )
113 print(kandidat_table)
114
115 # Menentukan model terbaik
116 idx_best <- which.min(kandidat_table$AIC)
117 cat("\nModel terbaik berdasarkan AIC:\n")
118 print(kandidat_table[idx_best,])
119
120 best_model <- switch(
121   idx_best,
122   model_011,
123   model_110,
124   model_111,
125   model_211
126 )
127
128 # Ringkasan koefisien best_model
129 cat("\nRingkasan koefisien model terbaik:\n")
130 print(summary(best_model))
131

```

```

132 # -----
133 # 4.4 Pembangunan, Pelatihan, dan Evaluasi Model
134 # -----
135
136 # 4.4.1 Pembangunan dan Pelatihan Model
137 # -----
138
139 # Train-Test Split
140 n <- length(closing_ts)
141 n_train <- floor(0.8 * n)
142 train_ts <- ts(closing_ts[1:n_train], frequency=1)
143 test_ts <- closing_ts[(n_train+1):n]
144
145 # Latih model ARIMA(0,1,1) di data train
146 final_model <- arima(train_ts, order=c(0,1,1))
147
148 cat("\nRingkasan model ARIMA(0,1,1) di data training:\n")
149 print(summary(final_model))
150
151 # Plot fitted vs aktual di data training
152 fitted_train <- fitted(final_model)
153
154 plot(train_ts, type="l", col="black", lwd=2,
155      main="Data Aktual vs Fitted Model ARIMA(0,1,1) pada Data Training",
156      ylab="Harga", xlab="waktu")
157 lines(fitted_train, col="blue", lwd=2)
158 legend("topleft", legend=c("Aktual", "Fitted"),
159      col=c("black", "blue"), lwd=2)
160
161 # -----
162 # 4.4.2 Evaluasi Model
163 # -----
164
165 # Forecast ke data test
166 h_test <- length(test_ts)
167 fc_test <- forecast(final_model, h=h_test)
168
169
170
171
172
173
174
175
176
177
178
179
180
181
182
183 # -----
184 # 4.5 Analisis Diagnostik Residual
185 # -----
186 checkresiduals(final_model)
187 checkresiduals(model_011)
188
189 # -----
190 # 4.6 Implementasi Peramalan
191 # -----
192 # fit ulang ke seluruh data
193 final_model_full <- arima(closing_ts, order=c(0,1,1))
194
195 # forecast 30 hari ke depan
196 forecast_30 <- forecast(final_model_full, h=30)

```

```

196 forecast_30 <- forecast(final_model_full, h=30)
197
198 # plot hasil peramalan
199 plot(forecast_30,
200      main="Peramalan 30 Hari ke Depan Harga Penutupan Saham INDF (ARIMA 0,1,1)",
201      xlab="Hari", ylab="Harga Penutupan")
202
203 # melihat ringkasan prediksi
204 print(forecast_30)
205
206 # jika ingin data frame tabel prediksi
207 pred_table <- data.frame(
208   Tanggal_Prediksi = seq(tail(data$Tanggal,1) + 1, by=1, length.out=30),
209   Harga_Prediksi = round(forecast_30$mean,2),
210   Lower_80 = round(forecast_30$lower[,1],2),
211   Upper_80 = round(forecast_30$upper[,1],2),
212   Lower_95 = round(forecast_30$lower[,2],2),
213   Upper_95 = round(forecast_30$upper[,2],2)
214 )
215
216 # tampilkan tabel prediksi
217 print(pred_table)

```

- Output dataframe hasil forecasting

```

> print(pred_table)
  Tanggal_Prediksi Harga_Prediksi Lower_80 Upper_80 Lower_95 Upper_95
1      2024-12-31      7698.94    7590.12    7807.76    7532.52    7865.37
2      2025-01-01      7698.94    7554.62    7843.27    7478.22    7919.67
3      2025-01-02      7698.94    7526.26    7871.62    7434.85    7963.03
4      2025-01-03      7698.94    7501.95    7895.94    7397.67    8000.22
5      2025-01-04      7698.94    7480.33    7917.56    7364.60    8033.29
6      2025-01-05      7698.94    7460.65    7937.23    7334.51    8063.38
7      2025-01-06      7698.94    7442.49    7955.40    7306.73    8091.16
8      2025-01-07      7698.94    7425.52    7972.36    7280.79    8117.10
9      2025-01-08      7698.94    7409.55    7988.33    7256.36    8141.53
10     2025-01-09      7698.94    7394.42    8003.47    7233.22    8164.67
11     2025-01-10      7698.94    7380.00    8017.88    7211.17    8186.72
12     2025-01-11      7698.94    7366.21    8031.67    7190.08    8207.81
13     2025-01-12      7698.94    7352.97    8044.92    7169.82    8228.07
14     2025-01-13      7698.94    7340.22    8057.67    7150.32    8247.57
15     2025-01-14      7698.94    7327.90    8069.99    7131.48    8266.41
16     2025-01-15      7698.94    7315.98    8081.91    7113.25    8284.64
17     2025-01-16      7698.94    7304.42    8093.47    7095.57    8302.32
18     2025-01-17      7698.94    7293.19    8104.70    7078.39    8319.49
19     2025-01-18      7698.94    7282.26    8115.63    7061.68    8336.21
20     2025-01-19      7698.94    7271.61    8126.28    7045.39    8352.49
21     2025-01-20      7698.94    7261.22    8136.67    7029.50    8368.38
22     2025-01-21      7698.94    7251.07    8146.82    7013.98    8383.91
23     2025-01-22      7698.94    7241.15    8156.74    6998.80    8399.08
24     2025-01-23      7698.94    7231.43    8166.45    6983.95    8413.94
25     2025-01-24      7698.94    7221.92    8175.97    6969.40    8428.49
26     2025-01-25      7698.94    7212.59    8185.30    6955.13    8442.76
27     2025-01-26      7698.94    7203.43    8194.45    6941.13    8456.76
28     2025-01-27      7698.94    7194.45    8203.44    6927.38    8470.51
29     2025-01-28      7698.94    7185.62    8212.27    6913.88    8484.01
30     2025-01-29      7698.94    7176.93    8220.95    6900.60    8497.29

```